小说分析与参考创作流程详解

从《遮天》约 20 MB 文本，到多书借鉴、热门题材选择和完整长篇生产。

> 最值得先处理的不是“再多分析几本”，而是把原文覆盖范围、实际计费、参考材料如何进入正文这三件事看清。

你关心的问题	本地实现的直接结论
《遮天》究竟怎么分析？	这次历史记录把约 681.6 万字符按章节合并成 12 个大段，先提炼笔记，再写分析小节。
花了多少 token？	可高度对应的调用记录共 4,587,987 token；拆书字段只显示 57,150。按当日官网空闲价回算约 ¥20.81，另有写法提取约 ¥0.06。
能同时参考几本？	主参考开书界面为单选；知识绑定可提供多份辅助材料，但没有完整的多书权重融合入口。
热门题材读了正文吗？	没有自动读取小说正文。番茄以榜单简介等为主，起点、晋江的当前采集字段更少。
生成长篇最稳的方式？	先做小范围有效参考，明确一个主方向，试写 3-5 章，用实际用量和返工率校准，再按保存进度推进。

对象：希望理解产品内部流程并寻找优化空间的使用者与开发者。 金额单位为人民币。模型价格核验于 2026-11-01；本地代码基线为 ai 分支 7b6a76d1。

报告包含真实记录、代码事实、估算与建议；每类证据均单独标明。没有为本报告重新调用付费创作模型。

阅读路线与证据边界

章节范围	内容	重点读者
03-04	当前模型配置、价格与整体工作流	先建立全局认识
05-09	导入、拆书、真实《遮天》用量、预算与缓存	想理解 20 MB 案例
10-13	参考开书、续写、多书辅助和写法资产	准备照着参考书创作
14-17	热门题材的证据范围、多选流程和费用	准备从市场信号开书
18-23	整书规划、逐章生成、记忆与分阶段预算	准备生成完整长篇
24-27	两个案例的执行方案、优化优先级与最佳实践	希望直接采取行动
28-30	费用复算、核验清单、代码与官方资料索引	需要追溯结论与验收

四种标签如何理解

实测：本地文件统计或数据库中已保存的调用用量；金额仍是用量乘价格的回算，不是供应商账单。代码事实：当前分支中的路径与约束。估算：带输入、输出和次数假设的预算。建议：可执行方法或尚未实现的改进方向。

本地快照的范围

只读核对了 server/dev.db 的模型设置、拆书、知识文档、调用用量和少量生产结果。仅有一份《遮天》拆书记录；没有查询到由它绑定创建的新书。热门题材已有扫榜快照，但尚无 AI 趋势报告，因此后续创作与雷达费用不能冒充历史实测。

当前指定的磁盘 TXT 与已导入数据库的文本不是完全相同的版本：标准化长度和去空白哈希均不同。报告分别计算，不把旧用量硬套到新文件；远端服务器或桌面应用若使用另一数据库，需重新核对配置。

正文没有复述《遮天》的具体情节。文中的创作示例只是说明如何抽象机制，不是对原著内容的鉴定。

当前模型配置决定怎么计费

读取项	本地保存值	对后续费用的含义
顶部当前选择	deepseek-flash；温度 0.7；单次输出上限 32,768	显式带入顶部选择的新任务通常使用 Flash。上限不是实际输出量。
任务路由	规划、写作、检查、修复、摘要等 11 项均为 deepseek-v4-pro	没有显式模型覆盖的调用走 Pro；热门题材服务属于这种情况。
这次《遮天》	保存并实际调用 deepseek-v4-pro	历史分析按 Pro 回算，不能拿当前顶部 Flash 价格解释旧任务。
向量检索配置	开启；openai / text-embedding-v2；本次索引失败	该模型名、连接和凭证需要先核对；本报告不编造其 embedding 单价。

官网单价：每 100 万 token，人民币

模型 / 时段	缓存未命中输入	缓存命中输入	输出
Flash 空闲	¥1.00	¥0.02	¥4.00
Flash 高峰	¥2.00	¥0.04	¥8.00
Pro 空闲	¥4.50	¥0.15	¥13.50
Pro 高峰	¥9.00	¥0.30	¥27.00

官网高峰时段：北京时间非中国法定节假日的周一至周五 09:00-12:00、14:00-18:00；其余为空闲时段。2026-11-01 是周日，本例使用空闲价。价格会变动，跨时段任务应逐次计算。

计算式：费用 = (未命中输入 × 输入价 + 命中输入 × 缓存价 + 输出 × 输出价) ÷ 1,000,000。未知缓存收益时，预算先按全部输入未命中。

当前官网两款模型均列 1M 上下文、最大 384K 输出；项目自身的输出配置、任务预算和模型兼容策略仍会进一步限制。

依据：S01、S02、D01；DeepSeek 官方价格表 [W01]。代码索引见文末；“估算”不代表已经发生的扣费。

三种开书入口如何汇合

01 明确你的创作来源

自己的灵感 / 已拆书作品 / 公开榜单市场信号

↓

02 把来源转成可执行的创作方向

参考书形成承接方案与写法；市场信号形成创作简报

↓

03 选择新书方向并确认项目规模

题材、读者期待、核心优势、前期承诺、章数与章长

↓

04 准备整书资产

故事宏观、书级约定、世界、角色、分卷策略

↓

05 在即将写到的位置细化规划

卷节奏板 → 连续章节路线 → 任务单与场景 → 执行合同

↓

06 逐章写作并闭合结果

草稿 → 验收 → 有限修复与复验 → 保存 → 事实与时间线回填

↓

07 复盘与继续

从保存边界推进；在作品来源页处理暂停与恢复；整理质量债并导出

三个入口共享后半段长篇生产能力，但输入证据不同。参考书能提供正文证据与写法；热门题材提供公开榜单中的市场线索；两者都不会代替新书自己的角色、世界规则和章节义务。

依据：S05-S10、S12-S14。代码索引见文末；“估算”不代表已经发生的扣费。

上传一本书以后，先发生什么

01 浏览器读取 TXT。识别编码候选，得到字符串并清除空字符。有效 UTF-8 会被优先考虑；乱码仍可能使目录识别和费用估计失真。

02 通过 JSON 请求上传。后端默认上限 20mb，即约 20 MiB（20,971,520 字节）；它约束整个请求体，不是只看文件名义大小。该 TXT 按浏览器上传格式模拟的请求约 20.38 MB，接近上限但低于它；代理还可能有自己的限制。

03 保存文档及版本。知识文档记录标题和启用状态；版本保存内容、内容哈希和字符数。拆书绑定具体版本，后续换文件应建立新版本。

04 按需建立章节目录。章节缓存属于文档版本。先用目录规则识别，无法可靠识别时可调用章节切分 Prompt，再失败则以整文一章保留可读性。

05 后台建立检索索引。开启 RAG 时，将文本切片、向量化并写入检索库。这是独立任务，不等于拆书，也不是已经“理解”全文。

> 上传成功、拆书成功、向量索引成功是三种不同状态，必须分别核对。

你的历史记录

《遮天》源文档仍在，记录字符数 6,815,659；章节缓存有 1,821 章。索引失败，错误为“Embedding API key is not configured for provider=openai.”，已尝试 5 次。拆书直接读取保存正文，因此仍可生成报告；这不能证明后续正文的原文 RAG 召回可用。

没有执行补索引、修改凭证或重跑任务。索引失败记录说明的是这次任务的配置问题，不代表项目不支持检索。

依据：S03、S04、D02。代码索引见文末；“估算”不代表已经发生的扣费。

拆书的实际 AI 调用链

01 **选择文档版本、章节范围与分析预设**

范围决定读多少原文；预设决定生成哪些报告小节

↓

02 **生成原文片段并查询本地笔记缓存**

缓存匹配则复用；未匹配则为每段调用一次结构化分析

↓

03 **提炼原文笔记**

摘要、事件、人物、设定、写法、卖点、读者信号与短证据

↓

04 **先生成拆书总览**

定位、题材、受众、优势与短板，供其他小节统一口径

↓

05 **并发生成其余已选小节**

只选相关笔记字段，保存可读正文、结构化结论和证据位置

↓

06 **阅读、校正、复用结果**

局部重跑；发布知识库；提取写法；进入参考开书

预设	生成内容	名义调用数，无缓存
快速	总览、结构、人物、文风	片段数 + 4
标准	快速四项 + 世界、主题、商业化卖点	片段数 + 7
完整	标准七项 + 时间线	片段数 + 8

名义次数不含章节切分的 AI 后备、格式修复、重跑、角色深度研究和发布索引。当前环境笔记并发 2、小节并发 2；并发缩短等待，但不会把费用除以 2。

依据：S04、S05。代码索引见文末；“估算”不代表已经发生的扣费。

20 MB《遮天》究竟读了多少

指标	当前磁盘 TXT	历史导入版本
原始文件 / 内容	20,058,431 字节；UTF-8	保存文本，不以原文件字节数计
原始 / 标准化字符数	7,344,433 / 7,183,486	6,815,659
分段规则识别的标题	2,094 个	1,821 个
达到最小正文长度的段	1,809 个	1,821 个
合并后 source notes 段数	12；每组约 151 个有效段	12；每组约 152 章
单个大段字符数	约 54.6 万-65.2 万	约 52.0 万-61.5 万
历史单次输入 token	未重新请求模型	334,036-410,436

两个分支很容易被误读

能识别章节时：超过 12 段就按顺序分组并连接原文，最终至多 12 个大段；没有再用 16,000 字符切开这些合并大段。本次历史记录属于此分支，基本覆盖可识别章正文，而不是只抽看前 12 个小片段。

不能识别章节时：先用约 10,000 字符目标、最高约 16,000 字符和 400 字符重叠切片，最终只保留前 12 片。因此“无章节长文本”的后半部可能没有进入基础拆书。这是另一条路径，不能拿来解释本次 12 个巨段。

> 界面“12 个片段”并不能说明输入只有 12 万字；快速拆书也不会自动缩小全文输入范围。

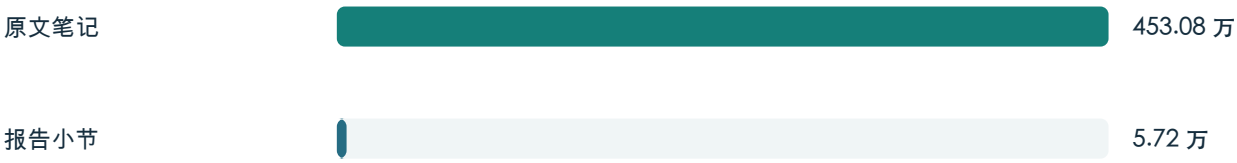
当前磁盘文件与历史版本去空白后仍不同。标题计数差异还包含短标题段过滤，不等于发现原著有缺章。分段复现按当前函数规则完成；报告未以模型 tokenization 冒充字符统计。

依据：S04、S05、D02、D03。代码索引见文末；“估算”不代表已经发生的扣费。

你这次拆书的真实用量回算

阶段	调用数	输入 token	输出 token	空闲价回算
原文笔记	12	4,517,961	12,876	¥20.4746
拆书报告小节	5	42,538	14,612	¥0.3402
拆书小计	17	4,560,499	27,488	¥20.8148
提取写法核心	1	2,875	1,717	¥0.0361
写法元数据与规则	2	4,472	153	¥0.0222
拆书 + 写法	20	4,567,846	29,358	¥20.8731

按实际记录的缓存命中计价：笔记 6,912，报告小节 11,136。合计拆书 4,587,987 token；写法另 9,217 token。余额赠送、税费或账单修正不在回算内。



原文笔记占拆书 token 的 98.75%。只从完整拆书改成快速拆书、而继续读全文，节约的是后端报告写作的小部分开销。改变原文范围或命中既有笔记缓存，才会显著影响这次规模的费用。

记录中的实际等待

北京时间 2026-11-01 15:28:11 至 15:32:27 生成笔记，约 4 分 16 秒；报告调用延续至 15:35:41，整体约 7 分 30 秒。写法提取约 27 秒。它们是一次成功样本，不能用作其他模型或高峰负载下的时延承诺。

唯一拆书记录与调用时间窗高度对应，但这些拆书调用未保存 analysisId / workflowTaskId 等关联字段，归属不是强外键证明。保存结果为 4 个小节，报告调用有 5 次；仅凭次数无法区分额外调用的具体原因。

依据：D01-D02、S05、W01。代码索引见文末；“估算”不代表已经发生的扣费。

预算、缓存与计量存在什么差异

> 历史预算为 60,000 token，usedTokens 为 57,150；实际可对应调用合计约 458.8 万。不能把该预算视为整次拆书的严格付费上限。

为何会出现差异

当前编排在小节生成完成后，将 section 的 usage 交给预算守卫；source notes 阶段返回笔记对象，没有把该阶段用量传入同一个预算守卫。全局调用账本能看到原文调用，拆书自身累计字段则漏掉这部分。并发且在调用后检查，也可能让多个在途调用超过阈值后才停止。

缓存能节约什么

本地笔记缓存匹配文档版本、全文/范围 key、厂商、模型、温度、笔记输出额度和分段版本。匹配成功可直接跳过原文笔记 AI 调用；这不同于供应商的输入缓存折扣。单节重跑通常复用笔记；已成功或冻结的小节在普通恢复时应保留。

历史缓存维度	该记录保存值
来源与范围	原导入文档版本 / full
厂商与模型	deepseek / deepseek-v4-pro
温度 / 笔记输出额度标识	0.7 / 0（当时未显式传入单节输出额度）
分段版本与片段数	1 / 12

顶部已切到 Flash。若新拆书沿用 Flash，或改了范围、温度、输出限制，就不能假定会命中旧 Pro 缓存。新任务即便显示同一本书，也要看来源版本与缓存身份。

应如何优化

在每次真实模型请求前预约预算，结果返回后按实际 usage 结算；把笔记、小节、修复、重试和角色研究统一归属到拆书任务。缓存按片段成功落账，避免一段失败使整批已经付费的笔记在下次重新生成。

依据：S05、S15、D02。代码索引见文末；“估算”不代表已经发生的扣费。

“照着一本书写”实际借鉴什么

比较项	参考创作新书	续写原作
产品意图	借结构机制、节奏、文风，生成独立角色、世界和剧情	延续既有角色、世界事实、终局状态与未完线索
必要拆书材料	剧情结构 + 文风与技法 + 商业化卖点	人物系统 + 剧情结构；原文版本须可读
建议额外材料	总览、主题；需要时研究人物功能与世界设计	时间线、世界规则、结局附近原文证据
承接方案输出	钩子、冲突循环、兑现节奏、转换方案、开篇 3 章方向	终局人物状态、未完线索、开篇 3 章方向
后续事实权威	新书自己的设定和已写正文	原作约束 + 新增剧情的已保存事实

真正的桥梁：创作承接方案

系统校验拆书状态及必需小节，将结构化结论和每节最多约 2,400 字符的可读摘录交给 AI，生成可审阅的承接方案。用户采用后，起始想法包含开篇 3 章和新书实现方向。这里消费的是拆书材料，并非重新通读整本原文。

进入参考开书页时，系统还会寻找同一拆书已启用的写法资产；找不到则从“文风与技法”提取，再补元数据和相关规则。这解释了你的记录中拆书之后出现的 3 次写法调用。

> 当前“快速拆书”没有商业化卖点；因此它适合先阅读判断，但不保证直接满足“参考创作新书”的承接材料合同。

短篇分支支持参考创作新短篇，入口规模为 3,000-30,000 字；续写入口要求选择长篇。本文费用主表以长篇为准。

依据：S06-S08、D02。代码索引见文末；“估算”不代表已经发生的扣费。

案例一：从你的《遮天》继续走下去

01 先确认要用哪个版本。若想复用既有分析，选择知识库中已导入版本；若使用指定目录下的新文件，建立新版本并接受重新分析费用。两者不能视为相同。

02 检查拆书是否可用于开书。本地记录处于 archived（归档），而主参考选择器只列 succeeded。应回到拆书来源页处理可用性或基于保留源版本建立新分析；不要在“运行记录”中寻找创作操作。

03 补齐借鉴创作所需材料。现有可读小节为总览、剧情结构、人物、文风；商业化卖点、世界、主题和时间线未生成且冻结。参考创作至少补商业化卖点；若准备续写，则优先核对人物终局、时间线和结局附近证据。

04 选择“参考创作新书”。明确只借机制。可填写：“借鉴层层揭开未知与阶段兑现的结构；使用全新的职业体系、地理空间、人物关系和冲突来源。”这是一种创作指令示例，不是对原著内容的结论。

05 生成并采用承接方案。核对钩子、冲突循环、兑现节奏及开篇三章。要求 AI 给出可执行转换，不要只给“宏大、热血、有悬念”等形容词。

06 确认写法与新书方向。先复用已提取的写法；生成候选方向，确认读者、卖点、目标章数与每章字数，再进入导演台。

07 先完成 3-5 章。看新书是否能独立成立，角色与设定是否串书，章节目标是否兑现；用实际 token、返工次数和章长校准全书预算，再继续分批推进。

本次核对没有发现这份拆书已绑定的新小说，因此这里描述的是接下来可执行的路径；不是声称你已经完成了承接开书。补齐小节若成功复用原文笔记，费用通常远低于重新读取全文。

依据：S05-S08、D02。代码索引见文末；“估算”不代表已经发生的扣费。

能否同时参考多本书

能力层级	当前支持情况	实际限制
主参考开书	一个 bookAnalysisId；单选	不能在这个入口直接勾选多本作为并列主参考
小说知识绑定	可以绑定多份启用文档	绑定不保证每次都会召回，也不保证索引成功
规划参考服务	部分大纲、设定、节拍路径可汇集绑定文档的成功拆书	合并上下文总截断约 5,000 字符；主参考优先，其他材料可能被挤掉
发布拆书结果	可形成结构化知识分块供检索	发布版是派生知识，不能冒充又读了一遍原文
多书融合合同	未发现完整的并列来源权重与冲突处理入口	不能承诺“选 3 本，各影响 1/3”或全过程自动融合

现阶段可执行的多书方法

选 1 本作主结构参考，另外 1-2 本各承担明确用途，例如人物关系推进、对白节奏。分别做适当范围的拆书，把要借的机制整理成简洁材料，再绑定到目标小说；新书默认写法保持一个明确主资产。

在起始想法中写清角色分工：“A 只借冲突升级；B 只借关系变化方式；C 只借场景表达节奏；不继承专名与世界事实。”这是一份用户指导，现有系统不会因此自动生成完整的多源权重控制。

费用怎样相加

每本的首次拆书费用相加。以后生成正文时只增加实际被选中的参考上下文，而不是每章重新发送几本全文。若都具有本例相近体量，Pro 空闲价下 3 本首次分析可约 ¥60-75；已有缓存、只分析片段或采用 Flash 时应另算。

特别注意：5,000 字符上限来自部分传统参考组装服务，不能据此保证新导演每个阶段都读到全部绑定材料。应检查实际 Prompt 或检索来源记录。

依据：S08、S09、S16。代码索引见文末；“估算”不代表已经发生的扣费。

拆书、写法资产与写作公式的分工

材料 / 功能	回答的问题	怎样进入生产
拆书报告	这份原文如何组织剧情、人物、设定和商业吸引力？	生成承接方案；部分规划参考；发布知识库
写法资产	这本新书在叙事、语言、人物表达与节奏上遵循什么规则？	绑定小说或场景，编译进正文、检查与修复上下文
写作公式	给定样文能提炼什么可复现步骤，如何生成或改写一段？	独立提取和应用调用；不是整本小说生产控制器
知识库材料	当前这一章需要哪些可溯源事实或参考？	语义/关键词检索后，选取有限片段进入上下文
书级创作约定	新书承诺给读者什么，哪些约束必须维持？	贯穿宏观规划、卷章任务和验收

“记住一本书”不是训练了一个新模型

导入、拆书与 RAG 都是在应用侧保存文本和结构化知识，再按需要放进后续请求；没有发现这条主流程进行模型权重训练。新调用仍需要付输入 token，缓存可以降低其中一部分费用。

写法提取为何既有价值也有损失

它能把参考书的技巧转成规则，减少整段原文反复塞入写作请求；但它来自拆书文风小节，信息已经经历“原文 → 笔记 → 报告 → 写法”的压缩。若想研究某种特别细的语言手法，应对有代表性的原文章节另做针对性分析。

> **结构参考、市场定位、语言风格和新书事实应该各有明确来源。不要靠把几本原文全塞进上下文来替代这层设计。**

依据：S07-S09、S16、S17。代码索引见文末；“估算”不代表已经发生的扣费。

热门题材参考的真实工作流

01 **获取公开榜单**

番茄 2 类、起点 3 类、晋江 3 类；当前解析器每榜最多 30 条

↓

02 **用户选择要分析的范围**

按榜单或逐本多选；请求合同最多 240 个条目 ID

↓

03 **按平台分别提炼市场信号**

每个有选中作品的平台 1 次 AI；去重同名同作者条目

↓

04 **跨平台综合**

结合平台摘要、可比较历史、题材和推进模式资源目录

↓

05 **选择 1-5 项信号与影响方式**

跟随热门 / 热门中求差异 / 弱化市场

↓

06 **生成创作简报与资源建议**

起始想法、核心优势、卖点、前 30 章承诺、题材和推进方式

↓

07 **进入自动导演**

修改开书设定 → 选择新书方向 → 准备资产 → 逐章生产

获取榜单是普通网页读取，不调用创作模型；AI 分析在用户确定作品范围后发生。选更多作品通常增加输入长度，不是按每本固定调用一次。

上述数量是当前代码上限，不保证外部页面总能返回这些条目。平台失败时保留已成功来源；公开站点结构变化会影响解析。

依据：S10-S12。代码索引见文末；“估算”不代表已经发生的扣费。

热门题材分析究竟看到了什么

来源	当前采集与输入	没有获得的证据
番茄	书名、作者、简介、标签、排名、部分热度/状态；简介存储截到 800 字符，进入分析时再截到 320	正文、完整章节结构、真实留存与付费转化
起点	书名、排名、作者、分类、部分热度字段；当前榜单解析不补正文或简介	不能据书名和分类确认完整开局、人物弧线或结局
晋江	主要为书名、排名与来源链接；当前解析不自动补足简介	缺少简介时，细化人物关系或剧情机制只能是弱推断
历史对比	同平台、同榜单的前次成功快照排名变化	没有历史时无法证明上升趋势；排名变化也不是销量因果

简介补抓不等于正文阅读

番茄条目存在混淆字符时，代码尝试读取作品详情页以恢复可读书名、作者和简介；正常条目不因此自动深抓。没有看到抓取章节目录并逐章阅读榜单作品正文的链路。

热度与拥挤度不是平台官方概率

AI 输出的热度、拥挤度等 0-100 分是基于给定榜单材料的结构化判断。它们可用于比较候选方向，但不能解释为“这个题材有 80% 成功率”。只看一次榜单还会有幸存者偏差、成熟作品偏差与平台读者差异。

> 如果问题是“读者最近在看什么”，用雷达；如果问题是“这本书怎样铺垫和兑现”，需要有正文证据的拆书。

本地快照中 8 个榜单读取成功，扫榜处于 ready；AI 趋势报告数量为 0。因此报告没有列出所谓“你当前最热门题材”，也没有把某次榜单信号当作已完成分析。

依据：S10-S12、D04。代码索引见文末；“估算”不代表已经发生的扣费。

案例二：多部热门作品如何变成一本新书

01 先限定一个目标读者场景。例如同一平台、相近频道与篇幅。先选 10-30 本新书或新晋作者作品，再少量加入成熟榜作对照；这是推荐样本规模，不是产品硬限制。

02 勾选多本后启动 AI 分析。核对报告中的证据来源，尤其检查是否只有书名而无简介。证据弱的条目不承担复杂剧情推断。

03 只带走 1-3 个相容的信号起步。产品允许最多 5 项，建议先用“一个题材基底 + 一个核心优势或关系卖点 + 一个差异化机会”。避免堆叠五种互相争夺主线的设定。

04 选择“热门中求差异”。它更适合新手在读者熟悉的方向里形成自己的卖点。生成简报后核对起始想法、核心优势、核心卖点与前 30 章承诺。

05 确定主要推进与辅助推进。当前开书合同有一个题材基底、一个主要推进、可选一个辅助推进。多个市场信号不等于多个题材 ID 在全书中拥有同等控制权。

06 让导演形成两套方向并选一套。要求说明“谁面临什么持续压力、每卷如何有新变化、结局怎样收束”，然后用前三章验证。

07 需要正文技巧时，补充单书分析。选代表作品的实际文本做拆书。若分别从两个入口获得材料，可把已确认的抽象结论写入开书想法并绑定对应知识；没有确认存在一个把所有来源一键融合的完整界面。

一组组合示例，而非实时榜单结论

“都市悬疑”作为舞台，“职业技能解决异常”作为核心优势，“破案必须支付关系代价”作为差异化。AI 应围绕同一主角欲望和持续冲突整合它们，不能只把三个标签放进简介。

依据：S10-S12、S06；样本规模与组合为本报告建议。代码索引见文末；“估算”不代表已经发生的扣费。

热门题材路径每个阶段要花多少

阶段	假设 / 名义调用	输入 / 输出 token	空闲价估算
获取榜单	普通 HTTP 与解析	创作模型 0 / 0	¥0 LLM 费
平台摘要	2-3 个平台各 1 次	合计 10k-30k / 4k-9k	¥0.099-0.257
跨平台综合	1 次；含资源目录与历史	6k-16k / 3k-6k	¥0.068-0.153
创作简报	1 次；选 1-5 项信号	1.5k-4k / 1k-2.8k	¥0.020-0.056
资源推荐补全	0-1 次或更多按实际缺口	0-8k / 0-2k	¥0-0.063
开书前市场小计	不含后续小说生产	17.5k-58k / 8k-19.8k	约 ¥0.19-0.53

k = 千 token。按全部输入未命中；当前市场服务未显式传入顶部模型，按保存的 planner 路由 Pro 估算。高峰时段同样 token 费用加倍。输入范围是假设，非本地已发生用量。

为什么不是“选 30 本就要分析 30 本正文”

平台内把选中条目归并为一份元数据摘要输入。名义基础调用数为 P + 1（P 为参与平台数），再加一次简报和按需资源推荐；平台摘要输出上限为 3,000，综合上限 6,000，简报上限 2,800 token。若发生格式修复或重试，物理调用会增加。

多选带来的主要增量

作品多选增加榜单元数据输入长度；信号多选主要增加简报复杂度。选满 240 个条目、较长资源目录或多轮重分析不在表中典型样本范围，应按实际请求重新估算。等待可先预留约 1-5 分钟用于 2-3 平台分析，网络与模型负载可能使其显著延长。

后续写 30 万字的成本基本来自共同长篇生产链，市场选择阶段通常只占小部分。雷达费用便宜，是因为它读的材料少，不能据此认为它与通读原文的拆书具有同样深度。

依据：S10-S12、W01；所有金额为估算。代码索引见文末；“估算”不代表已经发生的扣费。

从开书方向到可执行章节

顺序	资产 / 过程	解决的问题
01	故事宏观规划	主线、阶段目标、冲突动力与结局方向
02	书级创作约定	核心卖点、读者承诺、必须遵守的约束
03	本书世界	生成、复用或显式跳过；强设定小说先给角色共同规则
04	角色阵容	主角、对手、伙伴等叙事职责与初始资产
05	分卷策略	战略 → 评议 → 骨架；每卷的推进与兑现
06	目标卷节奏板	卷内阶段变化和起伏，不一次写完全文
07	章节路线窗口	正文授权下准备连续窗口，通常目标 5 章、最低 3 章；剩余范围可缩小
08	章节任务与场景	每章必须推进什么、哪些角色参加、如何落到具体场景
09	同步执行合同	将可用的规划转为章节执行输入并保护已保存正文
10	章节生产批次	调用正文生产链并核对保存结果是否闭合

长期目标可以是全书，但近期章目和场景应滚动细化。一次为几百章写死细节，容易与已经生成的人物状态和剧情结果冲突，也会扩大返工成本。当前新导演已有连续窗口准备的结构。

导演 V2 的“生产十步骤”与另一个灰度正文内核开关不同。后者默认关闭，现有运行会固定选择其正文实现；报告用共享的业务步骤解释，不把模块文件存在当作所有环境都启用。

依据：S13、S14。代码索引见文末；“估算”不代表已经发生的扣费。

每一章为什么会调用多次模型

01 **准备章节任务与上下文**

当前义务、角色硬事实、上一章实际结果、世界切片、可选资料

↓

02 **生成完整草稿并保存可恢复结果**

不是一次生成全书；空正文与接口错误单独处理

↓

03 **执行验收与必要的风格检查**

判断义务兑现、连续性、人物行为和表达问题

↓

04 **有修复价值时局部修复，再复验**

有限次数；没有产生新候选时避免为无变化文本付费复验

↓

05 **选择安全稿件并保存**

不以分数提高代替事实保持；保留可用原稿与修复记录

↓

06 **回填事实、摘要、资源与时间线**

更新后续章节会使用的状态；索引等副作用独立追踪

↓

07 **完成当前章，推进下一章**

保留质量债；需要全局重规划或明确人工策略时停在保存边界

完成优先：普通局部质量问题、可修补缺口和残留质量债不应自动让全书失败。质量优先：若保存策略明确决定人工暂停，应等待用户在作品来源页恢复，后台轮询不能擅自清掉暂停。

不可恢复且无可用正文、数据完整性问题或明确要求全局重规划可以停止。运行记录负责展示状态和导航，继续、重试、恢复等动作属于导演台或相应来源页。

依据：S14、S18、项目 AGENTS 质量与运行记录规则。代码索引见文末；“估算”不代表已经发生的扣费。

下一章到底会记得什么

信息	主要作用	费用与失效风险
章节义务与场景计划	约束当前章必须发生的事情	每章输入；合同缺失不能靠生成器自由猜测
角色硬事实	防止身份、能力、位置与关系矛盾	只拿相关人物与状态；不是发送全角色库
上一章结果与摘要	把已发生结果接到下一章	摘要失真会逐章放大；应以保存正文为准
书级约定与卷节奏	让局部章节服务全书承诺	长期信息需稳定、简洁；反复大段重复会增加输入
世界切片与写法	提供当前场景的规则和表达约束	避免把参考书事实当成新书世界事实
RAG 召回	按当前任务找少量相关材料	检索为空或索引失败，常按可选语义跳过；不能假设所有绑定文本都进入模型

两种典型误解

“上传到知识库了，所以 AI 每章都知道全文”不成立。当前配置最终检索默认 Top-K 为 8，随后还会受上下文装配预算限制；章节 RAG provider 的标称预算为 900 token，这只是该类块的策略值，并非整次请求总上限。

“生成了摘要，就不会忘记”也不成立。摘要、事实、时间线与章节任务应保留来源与版本，否则过时摘要可能覆盖真实正文。RAG 是补充，不能代替必需的角色事实、上一章结果和章节义务。

多本参考如何避免串书

把外部参考限定为“可借鉴机制”，把新书事实单独保存。若想在某章借鉴一段节奏，应记录来源、目的和转化要求；不要让检索到的外部人名、地点、规则直接成为本书事实。

依据：S09、S16、S18；D01 的 Top-K 配置。代码索引见文末；“估算”不代表已经发生的扣费。

21 / 100 章 × 3,000 字

30 万字长篇的分阶段 token 预算

表中假设：100 章，约 5 卷，按窗口准备路线；20%-40% 的章节做一次修复与复验；没有全书推倒重来；输入均按缓存未命中。各范围端点相加是压力预算，不是统计置信区间。

阶段	输入	输出	Pro / ¥	Flash / ¥
开书方向、宏观与约定	15-45k	5-15k	0.14-0.41	0.04-0.10
世界与角色准备	10-40k	5-18k	0.11-0.42	0.03-0.11
分卷、节奏、滚动章目	120-400k	25-90k	0.88-3.02	0.22-0.76
逐章任务、检查与即时规划	1,100-2,200k	180-400k	7.38-15.30	1.82-3.80
逐章正文草稿	600-1,400k	180-280k	5.13-10.08	1.32-2.52
首次章节验收	900-1,800k	50-150k	4.72-10.12	1.10-2.40
事实、摘要与时间线回填	800-1,600k	200-450k	6.30-13.28	1.60-3.40
局部修复 + 复验	400-1,200k	20-120k	2.07-7.02	0.48-1.68
总计	3,945-8,685k	665-1,523k	26.73-59.64	6.61-14.78

正文草稿的输出预算约每章 1.8k-2.8k token；但任务单、验收与回填也会输出内容。因此“30 万汉字 × 单个模型输出价”远不足以解释总费用。

当前设置同时存在顶部 Flash 与路由 Pro：实际应按每次调用的有效模型结算。双列给出同样工作量分别用两款模型的可复算价格包络，不代表质量相同，也不代表软件会自动把所有步骤统一切成 Flash。

不含参考书首次分析、可选深度角色研究、embedding、图片与语音、服务器开销、异常重试和重新规划整书。按旧 Pro 任务继续时优先参考 Pro 列；按顶部 Flash 新建且明确覆盖的阶段参考 Flash 列。

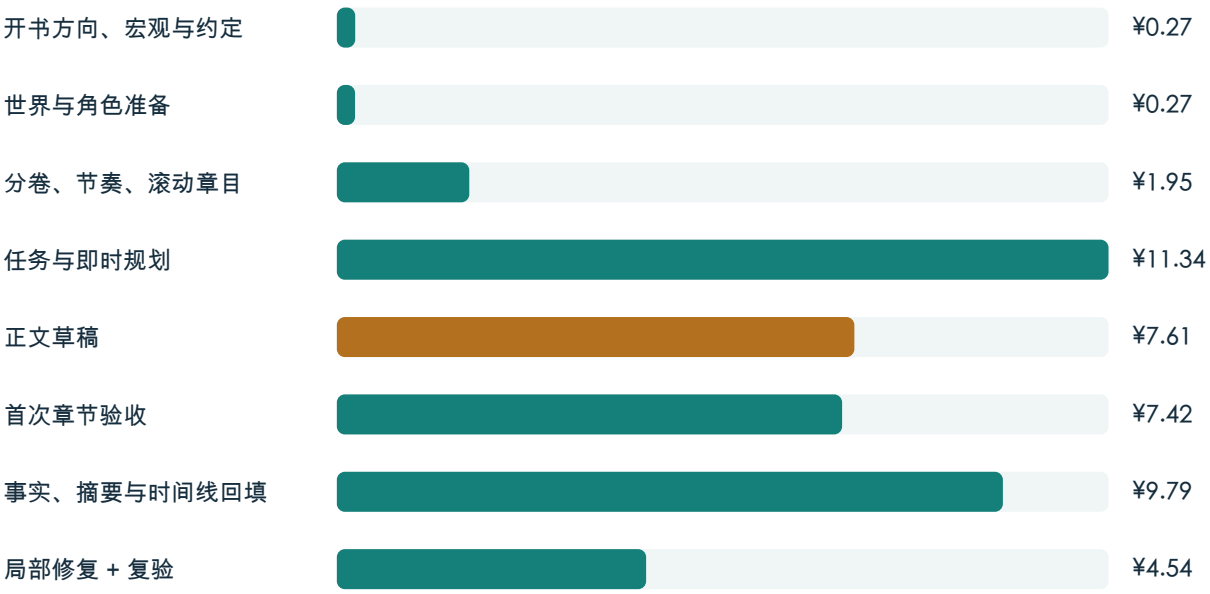
依据：S13-S18、D05 单章样本校准、W01。代码索引见文末；“估算”不代表已经发生的扣费。

预算随篇幅、模型与返工怎样变化

目标规模	章数假设	Pro 空闲价	Flash 空闲价
现有项目规模约 22.4 万字	80 × 2,800	约 ¥22-49	约 ¥5.5-12
统一示例 30 万字	100 × 3,000	约 ¥27-60	约 ¥6.6-14.8
中篇幅长篇 60 万字	200 × 3,000	约 ¥53-119	约 ¥13-29.5
百万字长篇	约 334 × 3,000	约 ¥88-199	约 ¥22-49

近似按章数缩放逐章部分、保持开书部分固定；22.4 万字取保守章数比例，没有假设输入随章长严格等比例下降。长书可能增加记忆整理、重新规划和跨卷检查，超出此近似。

30 万字的主要费用来源，取预算区间中点



缓存命中主要节约重复输入；输出费用仍存在。额外一次“修复 + 复验”通常多出两次上下文输入，若重写整章还会增加约整章输出。一次推倒重规划可能使已完成的规划与正文成为沉没成本。

高峰价约为这里的 2 倍。若运行跨越时段，用各次请求发生时的价格计算，不能只看任务启动时刻。

依据：W01；本页为预算敏感性模型。代码索引见文末；“估算”不代表已经发生的扣费。

哪些费用在主表之外

项目	典型 token / 计费量	如何估算
当前 TXT 首次全文分析	参考历史同模型比例，约 4.5M-5.2M 输入；20k-45k 输出	Pro 空闲约 ¥20.5-24.0；Flash 约 ¥4.6-5.4。模型差异、格式修复另计。
原文笔记命中后补 1 小节	约 6k-15k 输入；1.5k-4k 输出	Pro 约 ¥0.05-0.12；若缓存失配，不能只算小节费用。
创作承接方案	约 6k-18k 输入；1.5k-4k 输出	Pro 约 ¥0.05-0.14；Flash 约 ¥0.01-0.03。
深度角色研究	按角色、维度和回溯章节重复检索 / 生成	先报每名角色及覆盖范围；不自动包含在基础拆书中。
角色外貌扫描 / 配图	按扫描章节、图像生成次数计	不是小说正文生产必需项；图片不能套文本 token 单价。
索引与检索	embedding 输入 token；可选重排或上下文增强	单独按 embedding / rerank 供应商价格计算。

全文 RAG 索引的量级

历史版本约 681.6 万字符，按 800 字符块、120 重叠粗算约 1 万块，重叠增加约 18% 文本量。可先按约 4.8M-8.0M embedding token 留量，再用实际分词校准。若 embedding 价为每百万 p 元，一次索引约为 4.8p-8.0p 元；这不是使用 DeepSeek 文本输入价。

当前 embedding 配置未成功运行，无法给出真实金额。若启用“为每个块生成解释性上下文”的增强索引，还可能多出大量 LLM 调用；普通切片向量化与这种增强方式必须分别列账。

公式中的 M = 百万。字符与 token 的关系随分词器、空白和语言而变化。这里的索引数只用于容量预算，实际切片器还会按段落和模型 token 上限调整。

依据：S05、S16、D01-D03、W01；新增阶段均为估算。代码索引见文末；“估算”不代表已经发生的扣费。

两条案例的总预算怎样拼起来

情形	进入长篇前	30 万字生产	空闲价合计
历史 Pro 全文拆书 + 未来 Pro	已发生拆书与写法约 ¥20.87；承接和补节另约 ¥0.10-0.26	¥26.73-59.64	约 ¥47.7-80.8
当前 TXT 新跑，显式 Flash	全文分析约 ¥4.6-5.4；写法、承接和补节约 ¥0.03-0.10	¥6.61-14.78	约 ¥11.2-20.3
当前配置热门题材 → 显式 Flash 新书	雷达按 Pro 路由约 ¥0.19-0.53	¥6.61-14.78	约 ¥6.8-15.3
热门题材 → Pro 新书	雷达约 ¥0.19-0.53	¥26.73-59.64	约 ¥26.9-60.2

表中 Flash 生产列要求相关阶段显式使用 Flash；仍走 Pro 的阶段需单独替换。历史已付款费用是沉没成本，若只是从旧材料继续创作，新增预算应扣掉已发生的 ¥20.87。全部不含 embedding 和额外异常重试。

最适合你的实际预算方法

01 先确认有效主模型，并完成可复用的参考资产。不要因为“当前顶部选了 Flash”，就用 Flash 单价回算过去的 Pro 调用。

02 完成 3-5 章试写，统计每章输入、输出、缓存与修复次数。保留所有物理请求，包括格式修复与被业务校验拒绝的输出。

03 以试写后的平均逐章成本 × 剩余章数，再加尚未完成的规划与参考成本；另留 20%-30% 弹性额度。这是项目预算建议，不是自动执行的产品限额。

以 Pro 路径为例，首次全文参考 + 30 万字生产可以先留约 ¥60-105 的可用额度作低风险试算；若大量重写、换模型或追加多本全文分析，需重新计算。不要为了“花满预算”自动做额外研究。

依据：D02、W01；本页总额来自前述区间加总。代码索引见文末；“估算”不代表已经发生的扣费。

优先优化哪些地方

优先级	问题与证据	改进方向与验收标准
P0	拆书预算漏计 source notes；实际与 usedTokens 相差约 80 倍	所有物理请求共用任务计量与调用前预算预约；用原文笔记 + 报告 + 重试汇总核对，差异有明确解释。
P0	“完整拆书”代表维度全，不保证所有文本路径覆盖全文	在入口展示实际字符范围、分段大小、覆盖率与预计 token；无目录路径截断必须可见。
P1	章节识别后合并成 12 个巨段；每段只留下极少笔记	按模型输入预算做稳定片段，逐章/小组摘要 → 分卷综合 → 整书报告；每级保留证据链。
P1	快速拆书缺商业化卖点，参考创作必需材料未满足	按创作意图由 AI 推荐分析范围；在启动前显示必需维度，缺项时只补缺项并说明增量费用。
P1	本例索引失败，但拆书仍可完成；后续可能以为检索可用	分别展示文档、拆书、索引状态；进入依赖检索的动作前做可用性检查与实际召回验证。
P1	多书主参考缺融合合同；5,000 字符合并可能挤掉后源	先扩展结构化多源合同：来源、用途、优先级、转换、冲突裁决、证据；避免只增加多选框。

其中计量和覆盖率应先于扩大模型上下文。长上下文能让请求被接受，却不保证 150 多章压缩成一份短笔记后仍保留关键伏笔、人物变化与因果。

这些是分析结论与建议，本次没有修改运行行为。AI 语义理解仍应主导参考提炼与冲突判断；确定性逻辑只负责范围、预算、安全与已结构化结果的校验。

依据：S04-S09、D02；项目 AI-First 规则。代码索引见文末；“估算”不代表已经发生的扣费。

进一步优化质量与成本

方向	为什么值得做	如何判断真的有效
来源与版本贯穿	开书页选中不等于候选、书级约定和正文都消费到了	逐阶段显示有效参考 ID/版本、采用字段、被裁剪块；对新旧导演交接做契约测试。
市场证据分级	不同平台实际字段差异很大，弱证据易被包装成强结论	标明只有书名 / 有简介 / 有正文；无可比较历史不宣称趋势；保留可核对链接与抓取时间。
按片段缓存与恢复	整批笔记成功后才写缓存，局部失败可能带来重复读取	已完成片段可独立复用；修改一个范围不使其余范围全部失效；真实消耗不会重复计或漏计。
规划循环可解释	本地一次章目 Prompt 有 88 次调用；completed 不证明业务已接受	分清合法窗口、重试、格式修复和重复派发；限制无进展循环并保留已保存路线。
阶段有效模型可见	顶部 Flash 与路由 Pro 同时存在，用户难以预估	启动页列出每类步骤有效模型、覆盖来源和价格；运行账本显示真正请求的模型。
试写驱动的预算	固定“每章多少钱”不适合不同文风、章长和修复率	用前 3-5 章校准；同时报告每千字费用、修复比例、义务兑现率与人工接受率。

建议分三期完成

第一期：把计量、预算与原文覆盖做对。第二期：用分层摘要、片段缓存和多源合同提高参考可靠性。第三期：比较不同模型组合与试写结果，在读者体验不下降的前提下降本。

88 次章目调用是风险观察，不是已证实的单一 bug 根因；它可能包含多个规划窗口或业务重试。需要结合 run、范围和产物变化调查，不能直接删除记录或把全部费用判为浪费。

依据：D05、S13-S18。代码索引见文末；“估算”不代表已经发生的扣费。

这个项目创作长篇的最佳实践

01 先选一条主线。有明确参考书，就先研究它；没有方向，先用热门题材发现 1-3 个相容信号。把“读者为什么愿意继续看”说成一个具体承诺。

02 先缩范围，再选分析深度。借写法先研究有代表性的 10 万-20 万字；要理解全书结构再增加中段转折与结尾样本。分段样本报告不能标成已掌握全书因果。

03 先一主一辅，再考虑更多。一本负责主结构，一本只补一个缺口；明确不借人名和专有事实。多来源数量不是质量指标。

04 让 AI 给出“转化后是什么”。承接方案应具体到新主角、持续冲突、兑现机制和开篇三章。人物、世界和规则要在新书里自洽。

05 用前三章验证核心承诺。主角目标是否清楚、核心优势是否开始起作用、章末是否产生下一章的真实问题；不要先为了完整而堆大量世界设定。

06 规划远处保持粗，近期做到可执行。保留结局与卷级目标，按连续章节窗口细化任务和场景。每一章以已经发生的事实为依据继续。

07 默认完成优先，质量债可见。允许局部问题带着记录继续推进，在卷末集中复盘。需要质量优先时，接受明确人工暂停而不是后台偷偷继续。

08 每批结束做三项核对。正文是否保存、故事状态是否回填、下一批起点是否明确。用真实调用校准预算，在小说来源页恢复，不从“运行记录”操作工作流。

> 推荐起步组合：30 万字目标 + 一个主参考或一组市场信号 + 一个主写法 + 3-5 章试写 + 滚动生产。先完成一本能独立成立的小说，再扩展研究规模。

依据：前述代码事实与成本分析；本页操作策略为建议。代码索引见文末；“估算”不代表已经发生的扣费。

费用复算表与实际记录样本

《遮天》拆书的回算

未命中输入 = 4,542,451；命中输入 = 18,048；输出 = 27,488。 费用 = (4,542,451 × 4.5 + 18,048 × 0.15 + 27,488 × 13.5) ÷ 1,000,000 = ¥20.814824。

拆书总 token = 4,560,499 + 27,488 = 4,587,987；usedTokens = 57,150；比值约 80.28。后者与 5 次报告小节调用总量相同，不含 12 次原文笔记。

本地逐章调用样本，不等于完整成本基准

Prompt 用途	调用数	平均输入	平均输出
章节执行合同	2	4,957	1,464
任务单质量评估	2	4,259	99
即时章节规划	2	6,973	642
正文 writer	2	7,612	1,764
章节验收	3	11,199	630
事实/资源增量提取	2	6,996	2,071
时间线提取	2	3,135	1,749

本地仅 2 章正文样本，保存字数约 2,263 与 2,945；第一章 completed，第二章 pending_review。验收次数多于正文次数；不能把所有调用简单除以章数就宣称全书稳定单价。

你的预算公式

预计剩余费用 = Σ [每阶段剩余调用数 × (平均未命中输入 × 对应输入价 + 平均命中输入 × 缓存价 + 平均输出 × 输出价)] ÷ 1M，再加索引和其他独立收费。若模型或时段不同，先分组再相加。

依据：D02、D05、W01。代码索引见文末；“估算”不代表已经发生的扣费。

代码依据索引

以下路径相对于 /Users/likai/go/src/write/AI-Novel-Writing-Assistant。基线 7b6a76d1；范围只说明定位位置，不代表所有代码路径已做真实模型端到端验收。

S01 显式模型覆盖、路由和厂商默认的优先级

server/src/llm/factory.ts:220；modelRouter.ts:200

S02 顶部模型的保存事实源

server/src/services/settings/LLMSelectionSettingsService.ts；docs/wiki/architecture/model-selection.md

S03 TXT 解码、请求上限、文档版本、章节缓存与索引排队

client/src/lib/textFile.ts:176；server/src/app.ts:95；server/src/services/knowledge/KnowledgeService.ts:211；DocumentChapterService.ts:65

S04 目录识别、12 段合并与无目录截取

server/src/services/bookAnalysis/shared/bookAnalysis.utils.ts:200；shared/bookAnalysis.constants.ts:3

S05 笔记缓存、预算守卫与小节累计；路径同属 bookAnalysis

server/src/services/bookAnalysis/caching/bookAnalysis.cache.ts:36；caching/bookAnalysis.budget.ts:31；bookAnalysis.generation.ts:119

S06 单选主参考、模式跳转、写法准备

client/src/pages/novels/components/ReferenceNovelStartDialog.tsx:30；autoDirector/AutoDirectorCreatePage.tsx:222

S07 参考创作材料与承接方案合同

shared/types/creativeCarryoverContract.ts:85；server/src/services/novel/director/reference/CreativeCarryoverContractService.ts:118

S08 各阶段参考、绑定分析、截断上限

server/src/services/novel/NovelReferenceService.ts:20、229、323、423

S09 知识范围解析、拆书发布

server/src/services/knowledge/common.ts:52；server/src/services/bookAnalysis/publish/bookAnalysis.publish.ts

S10 榜单来源、元数据解析和简介范围

server/src/modules/marketRadar/infrastructure/marketRadarSources.ts:16、70、111、129

S11 条目格式化、多选信号、平台与跨平台分析

server/src/modules/marketRadar/application/MarketRadarService.ts:145、478、613

S12 多选数量、AI 元数据分析约束

server/src/modules/marketRadar/http/marketRadarRoutes.ts:15；server/src/prompting/prompts/marketRadar/marketRadar.prompts.ts:31

更多依据与验收清单

S13 导演十步骤、滚动路线与资产保护

server/src/modules/director/steps/planDefinition.ts:4；steps/README.md

S14 正文闭环与新内核开关

server/src/services/novel/runtime/chapterRuntimePipeline.ts:203；server/src/app/director/productionKernel/batch/router.ts:4

S15 调用用量账本与输入缓存字段

server/src/llm/usageTracking.ts；server/src/prisma/schema.prisma:4296

S16 索引、召回与章节上下文边界

server/src/config/rag.ts:97；server/src/services/rag/utils.ts:3；server/src/services/novel/runtime/context/chapterContextProviderContracts.ts:15

S17 写法资产与写作公式分工

server/src/services/styleEngine/StyleProfileService.ts:432；server/src/services/writingFormula/WritingFormulaService.ts:61

S18 生产保存、恢复与开书交接边界

docs/wiki/workflows/chapter-production-chain.md；server/src/modules/production/README.md；server/src/app/director/newBook.ts:12

本地证据编号

D01：AppSetting.llm.currentSelection、ModelRouteConfig 与安全的 RAG 配置；未读取或展示密钥值。
D02：唯一《遮天》BookAnalysis、关联小节、源版本、source cache、同时间窗用量及失败索引。
D03：指定磁盘文件的字节/字符/哈希与当前分段规则复现。
D04：MarketScanRun、8 个成功榜单快照、0 份 MarketTrendReport。
D05：135 条调用用量中的生产样本与 2 章保存正文长度；未把无关联的费用强行计入《遮天》开书。

W01：DeepSeek 官方模型与价格，访问日期 2026-11-01。金额是当前公开价回算；最终扣款以供应商账单为准。

应用前的五项验收

① 来源版本与分析范围正确；② 当前任务有效模型与单价明确；③ 必需拆书小节齐全且承接方案已采用；④ 依赖的索引实际可召回；⑤ 试写后的保存、回填、质量债和新增预算都可解释。

本报告的验证范围是代码阅读、本地只读统计、价格核验与 PDF 排版检查。未重跑创作链、未更改配置或数据库、未代替你进行界面验收。报告中的优化项需要另立实施与验证范围。